



A OTRO
NIVEL

VIRTUAL

REGRESIÓN LINEAL SIMPLE, MULTIVARIADA, POLINOMIAL Y MÉTRICAS

UNIDAD 1: Regresión Lineal



Agenda

01

Acercamiento intuitivo

02

Descripción matemática

03

Aplicación

04

Estimación de parámetros

05

Lecturas complementarias

06

Práctica en Google Colab


07

¡Comprueba tu conocimiento!

01

Acercamiento intuitivo

Regresión lineal simple, multivariada, polinomial y métricas



¿Qué es la Regresión?

Objetivo: Ajustar modelos para predecir valores continuos de la variable objetivo (**target**) con respecto a una o varias variables independientes (**predictores**).

Métodos:

Regresión lineal (simple y múltiple).


Regresión polinomial.

KNN.

Árboles de regresión.

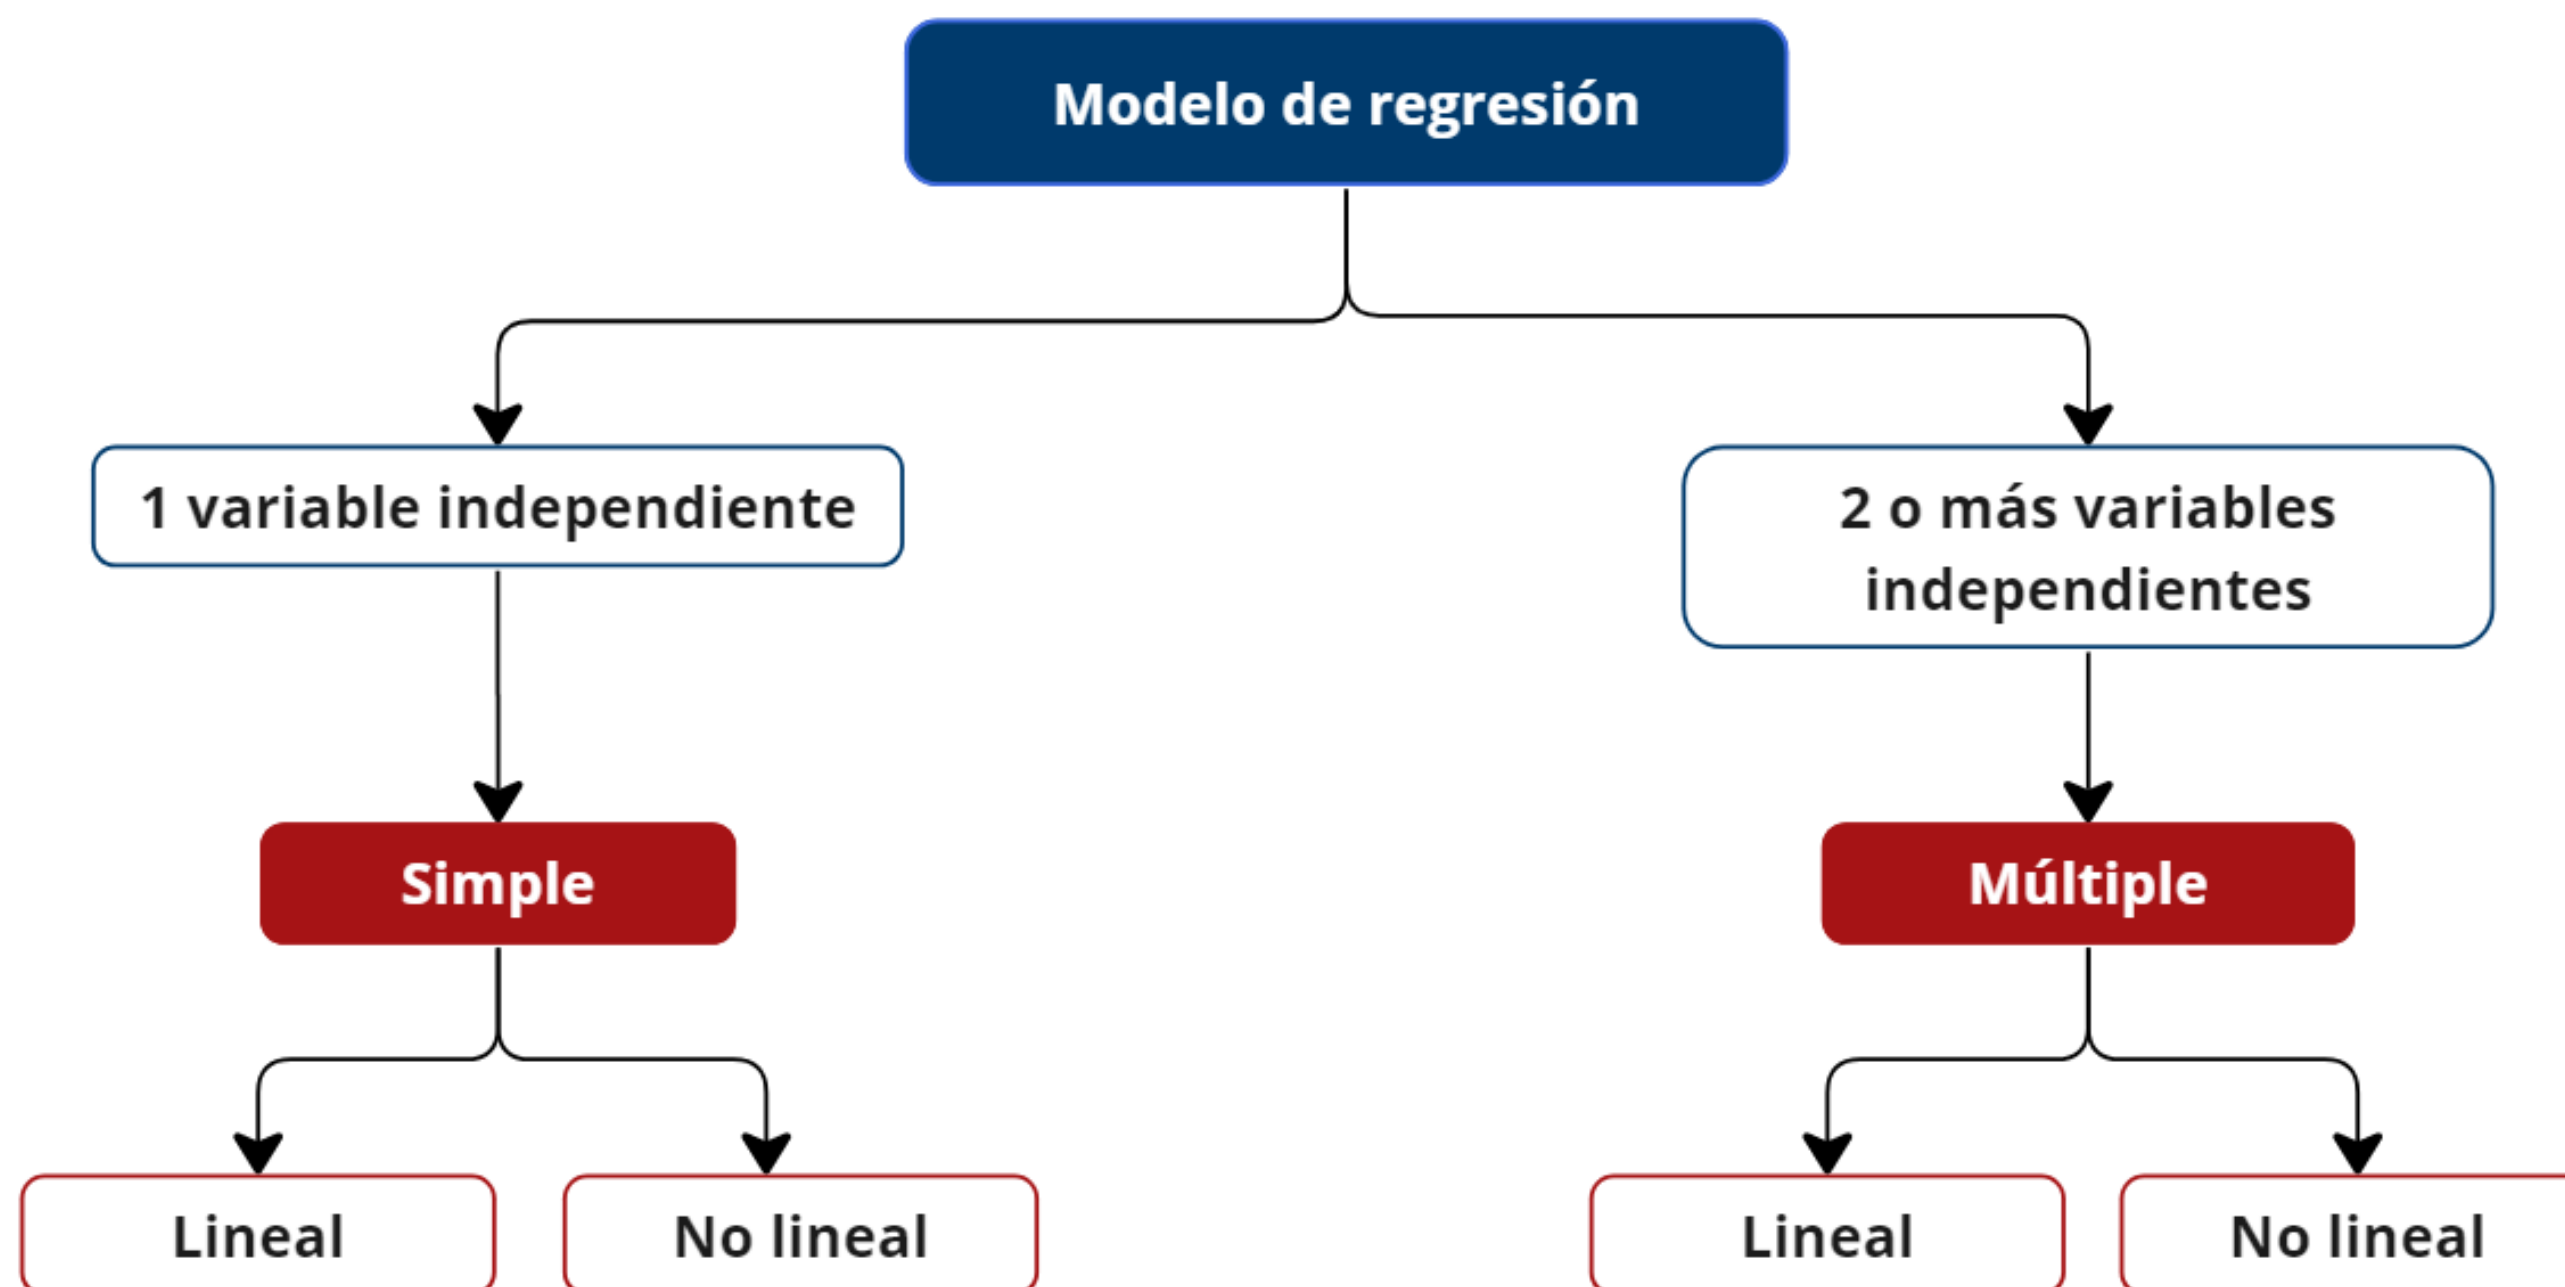
Línea base (baseline): evaluación dada por un modelo que predice una medida de tendencia central (e.g.: el promedio).

¿Qué es la Regresión?




Construye una **línea o curva** que **pasa a través de todos los puntos de datos** en el gráfico de predicción objetivo de tal manera que la distancia vertical entre los puntos de datos y la curva de regresión es **mínima**.


Tipos de modelos de Regresión



Linear



Non Linear



En el gráfico de la derecha se presenta una relación no lineal entre la variable dependiente y la independiente. Por lo tanto, la **línea de regresión no pasa a través de los puntos** de manera significativa.

Dado que esto no es posible, el modelo de regresión no puede interpretar significativamente los coeficientes o podría haber errores en la predicción.

02

Descripción matemática

Regresión lineal y Residuo
Métricas

Regresión lineal Simple

Intercepto


Pendiente

Error aleatorio


$$h(x) = \theta_0 + \theta_1 \cdot x + \epsilon$$

Variable Dependiente (respuesta - y)


Variable Independiente (Explicatoria)



Regresión lineal Simple



Residuo



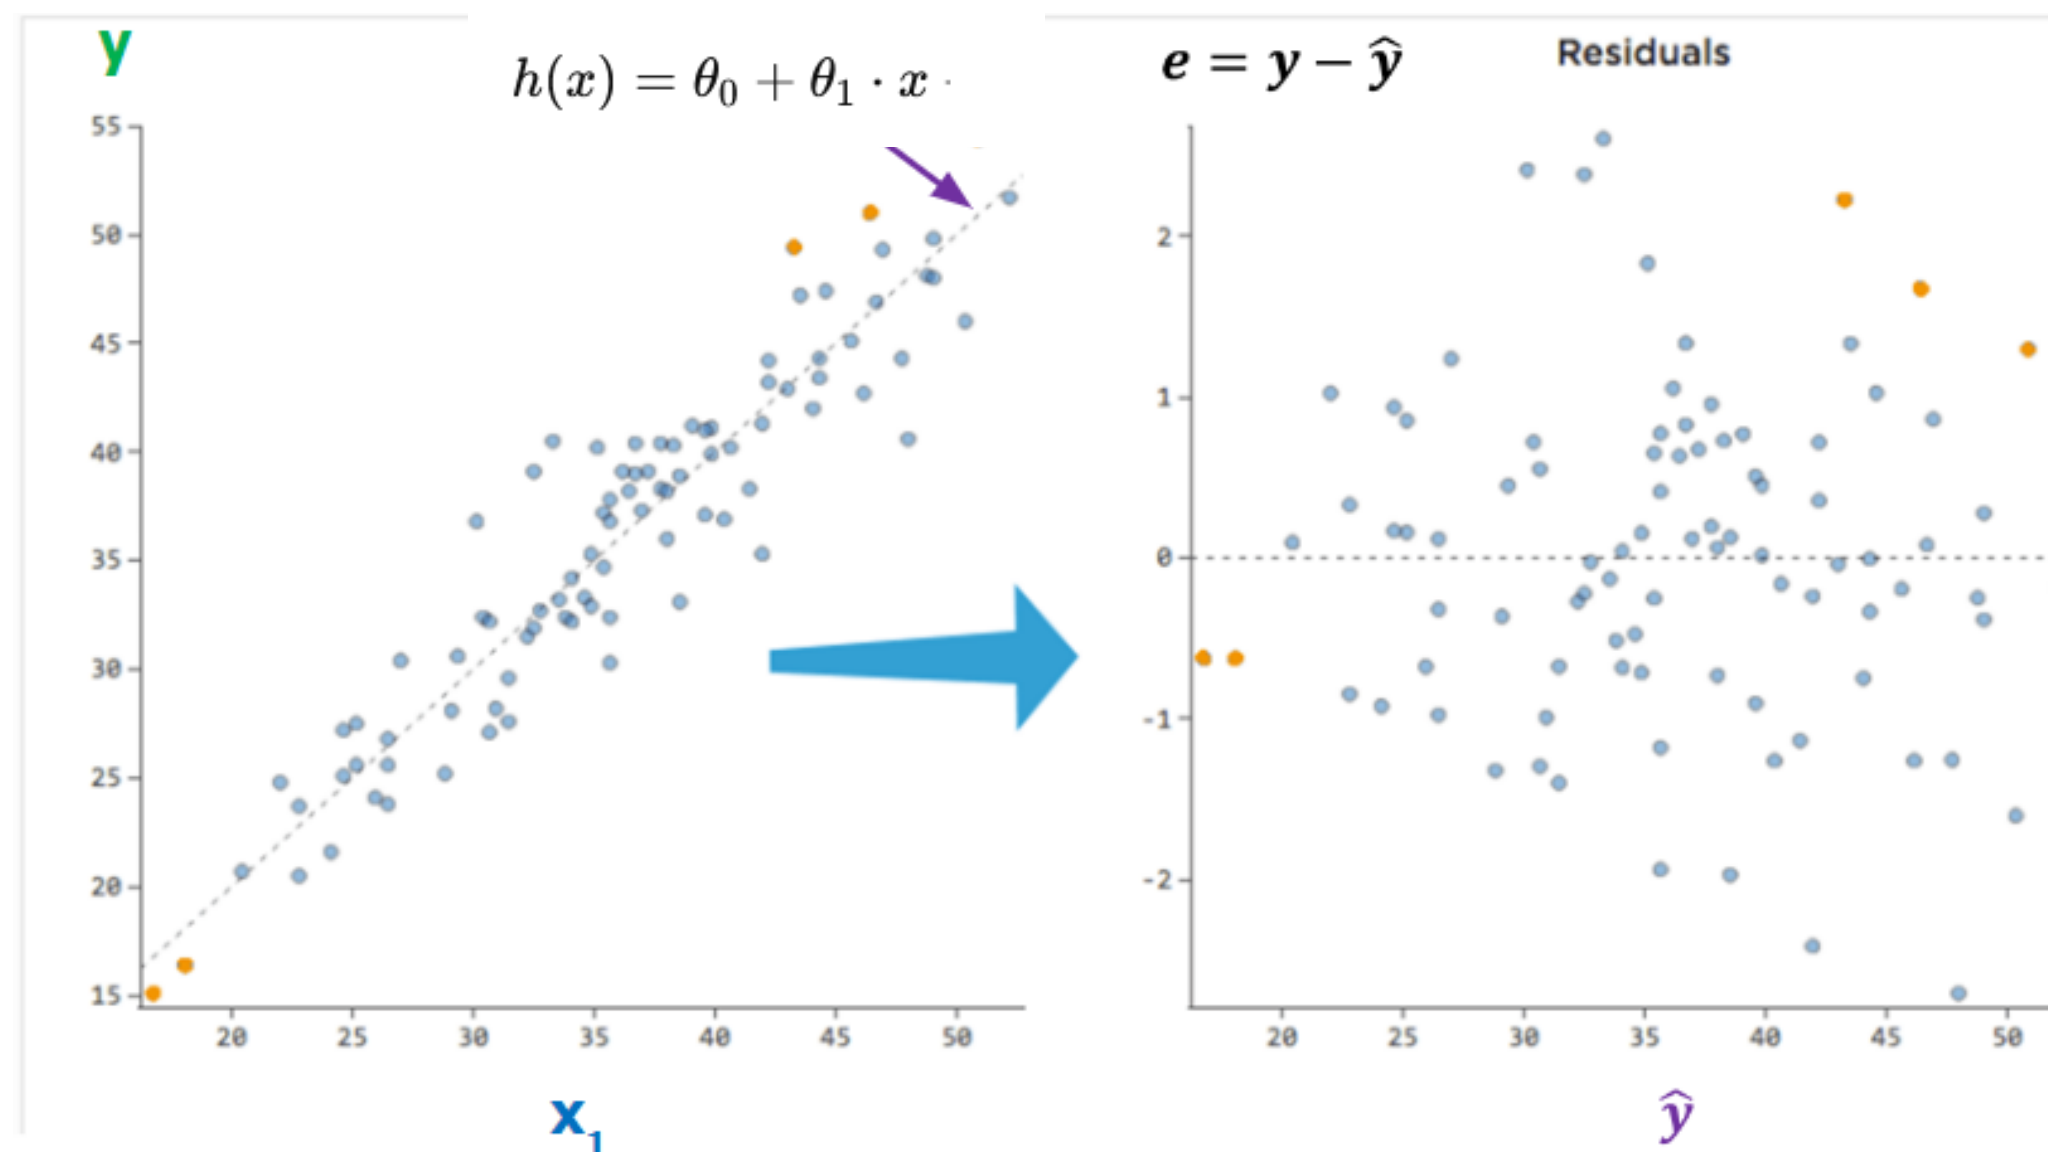
- La distancia entre los datos y la curva construida.
- Indica si el modelo ha capturado la relación entre los predictores y la variable objetivo.

Residuo (e) =
valor observado de salida - valor predicho

$$e = y - \hat{y}$$

Los modelos de regresión buscan minimizar el valor de **e** para el conjunto de predictores de entrenamiento.

Residuo



La gráfica de los residuos puede ayudar a identificar si el modelo de regresión ha capturado la relación entre la variable objetivo y los predictores.

Dado un conjunto de datos con m ejemplos:

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$$

donde:

- $x^{(i)}$ representa la variable de entrada del i -ésimo ejemplo,
- $y^{(i)}$ es la salida real (valor esperado),
- $h_{\theta}(x^{(i)})$ es la predicción del modelo para el ejemplo i .

$$h_{\theta}(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$h_{\theta}(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

Para cada punto $(x^{(i)}, y^{(i)})$, la diferencia entre la predicción $h_{\theta}(x^{(i)})$ y el valor real $y^{(i)}$ es el **error residual**:

$$e^{(i)} = h_{\theta}(x^{(i)}) - y^{(i)}$$

Si queremos medir el **error total** en todos los datos, sumamos estos errores para todos los ejemplos:

$$\sum_{i=1}^m e^{(i)} = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

¿Podemos usar la suma directa de los errores?

$$\sum_{i=1}^m e^{(i)} = \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$



Función de costo

Elevar al cuadrado los errores:

$$\sum_{i=1}^m (e^{(i)})^2$$

Esto garantiza que todos los errores sean positivos y penaliza mas los errores grandes.



La función de costo $J(\theta_0, \theta_1)$ mide el error cuadrático medio entre las predicciones del modelo $h(x)$ y los valores observados y .

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right)^2$$

- ◆ ¿Por qué dividir por $2m$?
 - El término $\frac{1}{m}$ obtiene el **promedio** del error cuadrático.
 - El $\frac{1}{2}$ se usa para simplificar la derivada en **gradiente descendente**.

Conversión de la Función de Costo OLS a Notación Matricial

En regresión lineal simple, el modelo se define como:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Para representar esta ecuación en forma matricial, escribimos:

$$h_{\theta}(X) = X\theta$$

Extendemos la matriz de características a la siguiente forma

Matriz de características X de dimensión $(m \times 2)$ incluye el término de sesgo (1) y la única variable x :

$$X = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(m)} \end{bmatrix}$$

Expresamos el vector de parámetros de la siguiente forma

θ de dimensión (2×1)

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix}$$

Expresamos la salida o variable objetivo de la siguiente forma:

Vector de valores reales y de dimensión $(m \times 1)$:

$$y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

Entonces el vector de predicciones para todos los ejemplos es:

$$h_{\theta}(X) = X\theta = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(m)} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix} = \begin{bmatrix} \theta_0 + \theta_1 x^{(1)} \\ \theta_0 + \theta_1 x^{(2)} \\ \vdots \\ \theta_0 + \theta_1 x^{(m)} \end{bmatrix}$$

La función de costo en su forma escalar es:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Podemos escribir esta suma como un producto de matrices:

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

Métricas de evaluación


En regresión lineal, los residuales son las diferencias entre los valores observados de la variable dependiente y y los valores predichos por el modelo $h(x)$. Se calculan de la siguiente manera:

$$\text{Residual} = y - h(x)$$

- y : Valor observado de la variable dependiente.
- $h(x)$: Valor predicho por el modelo, calculado como:

$$h(x) = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2 + \dots + \theta_n \cdot x_n$$

- $y - h(x)$: El residual, que mide el error de predicción para cada observación.



Métricas más utilizadas

MSE

$$\frac{1}{m} \sum_{j=1}^m \left[\left(y^{(j)} - h_{\theta} \left(x^{(j)} \right) \right)^2 \right]$$

RMSE

$$\sqrt{\frac{1}{m} \sum_{j=1}^m \left[\left(y^{(j)} - h_{\theta} \left(x^{(j)} \right) \right)^2 \right]}$$

R² (coeficiente de determinación)

$$1 - \frac{\sum_{j=1}^m \left[\left(y^{(j)} - h_{\theta} \left(x^{(j)} \right) \right)^2 \right]}{\sum_{j=1}^m \left[\left(y^{(j)} - \bar{y} \right)^2 \right]}$$

03

Aplicación

Dataset para predecir las ventas del siguiente año de 200 tiendas


Predicción de ventas

Una reconocida app lo ha contratado para que los ayude a predecir las ventas del año siguiente de 200 tiendas en toda España.



	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	2210.0
1	44.5	39.3	45.1	1040.0
2	17.2	45.9	69.3	930.0
3	151.5	41.3	58.5	1850.0
4	180.8	10.8	58.4	1290.0
...
195	38.2	3.7	13.8	760.0
196	94.2	4.9	8.1	970.0
197	177.0	9.3	6.4	1280.0

Predicción de ventas




Predicción de ventas

	Coefficient
TV	4.604620
Radio	18.615614
Newspaper	0.087046

- Por cada euro que invertimos en **Televisión** suben 4.6€ las ventas.
- Por cada euro que invertimos en **radio**, suben 18,6€ las ventas.
- Por cada euro que invertimos en **prensa**, suben 0.08€ las ventas.

Ventas reales y las predicciones realizadas



01

Estimación de parámetros

Algoritmo OLS y Gradient descent

Actualización de parámetros

El algoritmo de **gradiente descendente** ajusta los parámetros θ de una función de costo $J(\theta)$ utilizando la regla de actualización:

$$\theta = \theta - \alpha \frac{\partial J}{\partial \theta}$$



Donde:

- α es la **tasa de aprendizaje**,
- $\frac{\partial J}{\partial \theta}$ es el **gradiente de la función de costo** respecto a los **parámetros**.

1. Derivada en funciones compuestas

Si tenemos una función compuesta $f(g(x))$, su derivada se expresa con la **regla de la cadena**:

$$\frac{d}{dx}f(g(x)) = f'(g(x)) \cdot g'(x)$$

$$J(\theta) = L(h_{\theta}(x), y)$$

$$\frac{\partial J}{\partial \theta} = \frac{\partial J}{\partial h} \cdot \frac{\partial h}{\partial \theta}$$

Los parámetros se ajustan iterativamente utilizando las derivadas parciales de la función de costo con respecto a θ_0 y θ_1 .

$$\theta_0 := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

α : Tasa de aprendizaje, que controla el tamaño de los pasos en la actualización de los parámetros.

$\frac{\partial}{\partial \theta_0}$ y $\frac{\partial}{\partial \theta_1}$: Gradientes de la función de costo respecto a θ_0 y θ_1 .

Derivación del Gradiente

Derivada respecto a θ_0 :

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} = \frac{\partial}{\partial \theta_0} \left(\frac{1}{2m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right)^2 \right)$$

Expandiendo $h(x^{(i)}) = \theta_0 + \theta_1 \cdot x_1^{(i)}$:

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right)$$

Derivada respecto a θ_1 :

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} = \frac{\partial}{\partial \theta_1} \left(\frac{1}{2m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right)^2 \right)$$

Expandiendo $h(x^{(i)}) = \theta_0 + \theta_1 \cdot x_1^{(i)}$:

$$\frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right) \cdot x_1^{(i)}$$

$$\theta_j := \theta_j - \alpha \cdot \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_j}$$


• Actualización de θ_0 :

$$\theta_0 := \theta_0 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right)$$


• Actualización de θ_1 :

$$\theta_1 := \theta_1 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m \left(h(x^{(i)}) - y^{(i)} \right) \cdot x_1^{(i)}$$

Metodología para entrenar un modelo



Metodología para entrenar un modelo



Regresión Lineal Múltiple

La regresión lineal múltiple es un modelo estadístico que describe la relación entre una variable dependiente y y múltiples variables independientes x_1, x_2, \dots, x_n . El modelo se expresa como:

$$h(x) = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2 + \dots + \theta_n \cdot x_n + \epsilon$$

- $h(x)$: Predicción del modelo.
- θ_0 : Término de intersección.
- $\theta_1, \theta_2, \dots, \theta_n$: Coeficientes que indican la influencia de cada variable independiente x_i sobre y .
- ϵ : Término de ruido, que representa la variabilidad no explicada por el modelo.

Regresión Lineal Múltiple

El modelo se puede expresar de la forma

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x,$$

Y la función objetivo se expresa de la siguiente forma

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

Algoritmo LMS

Queremos elegir θ para minimizar $J(\theta)$.

Específicamente, consideremos el algoritmo de descenso de gradiente, que comienza con un θ inicial y realiza la actualización repetidamente:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta).$$

Algoritmo LMS



$$\begin{aligned}
 \frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{1}{2} (h_{\theta}(x) - y)^2 \\
 &= 2 \cdot \frac{1}{2} (h_{\theta}(x) - y) \cdot \frac{\partial}{\partial \theta_j} (h_{\theta}(x) - y) \\
 &= (h_{\theta}(x) - y) \cdot \frac{\partial}{\partial \theta_j} \left(\sum_{i=0}^n \theta_i x_i - y \right) \\
 &= (h_{\theta}(x) - y) x_j
 \end{aligned}$$

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}.$$

Regresión Polinomial

- Regresión polinomial en una variable (**predicción**):

$$h_{\theta}(x) = \theta_0 + \theta_1 \times \text{frontage} + \theta_2 \times \text{depth}$$



$$\begin{aligned} h_{\theta}(x) &= \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 \\ &= \theta_0 + \theta_1(\text{size}) + \theta_2(\text{size})^2 + \theta_3(\text{size})^3 \end{aligned}$$

$$x_1 = (\text{size})$$

$$x_2 = (\text{size})^2$$

$$x_3 = (\text{size})^3$$

Regresión Polinomial

- Regresión polinomial en una variable (**predicción**):

La regresión polinomial es una extensión de la regresión lineal que permite modelar la relación entre una variable dependiente y y una variable independiente x mediante un polinomio de grado n . El modelo se expresa como:

$$h(x) = \theta_0 + \theta_1 \cdot x + \theta_2 \cdot x^2 + \dots + \theta_n \cdot x^n + \epsilon$$

- $h(x)$: Predicción del modelo.
- θ_0 : Término de intersección.
- $\theta_1, \theta_2, \dots, \theta_n$: Coeficientes del polinomio que determinan la forma de la curva.
- x^n : Potencias de la variable independiente x , que permiten capturar relaciones no lineales.
- ϵ : Término de ruido, que representa la variabilidad no explicada por el modelo.

